# Projekt-Bericht und Dokumentation im Kurs Wissensrepräsentation SoSe15

Lukas Hodel

Richard Remus

21. Juli 2015

# Inhaltsverzeichnis

1	Auf	gabenstellung	4		
2	Idee				
	2.1	Lobbyradar	5		
	2.2	Ziel	5		
	2.3	Vorgehen	5		
3	Ana	lyse Lobbyradar	6		
4	Auf	bau der Ontologie	8		
	4.1	Konvertierung der Daten in RDF	8		
	4.2	T-Box	8		
	4.3	A-Box	9		
5	Benutzung des Programms, Lobbyradar				
	5.1	Nach Personen suchen	11		
	5.2	Verbindungen einer Person ausgeben	11		
	5.3	Resultat plotten	11		
	5.4	Nach Organisationen suchen	12		
	5.5	Verbindungen einer Organisationen ausgeben	12		
	5.6	Verbindungen einer Organisationen plotten	13		
	5.7	Nach Bundes-Organisationen suchen	13		
	5.8	Eigene Sparql abfrage erstellen	15		
	5.9	DBpedia-Informationen einer Person anzeigen	16		
	5.10	Eigene Sparql Anfrage an DBpedia senden	16		
6	Nachbetrachtung 19				
	6.1	RDF-Validierung	19		
	6.2	Real-World-Datensatz	19		

7	Nachbetrachtung		
	7.1	Weitere Klassifikationen	20
	7.2	SPARQL-Endpoint	20
	7.3	Fazit	20

## 1 Aufgabenstellung

Die gegebene Aufgabenstellung lautete:

Führen Sie ein Semantic Web / Linked Data Projekt durch. Dies sollte mehrere der folgenden Aspekte umfassen:

- Verknüpfen von verschiedenen Datenquellen
- Konvertierung von Daten ins RDF-Format (mit entsprechender T-Box)
- Entwicklung von Ontologien
- Linked Data Anwendung
- Informationsextraktion/Web Scaping und Konvertierung in RDF
- Entity Resolution
- ..

#### 2 Idee

Wir haben im Kurs bereits Erfahrungen mit dem Lobbyradar des ZDF und DBpedia gemacht.

#### 2.1 Lobbyradar

Das Lobbyradar ist eine vom ZDF zusammengestellte Datenbank, welche die lobbyistischen Verbindungen zwischen Regierungsorganisationen und der Privatwirtschaft transparent machen sollte. Das Lobbyradar besitzt ein Frontend auf dem man sich bequem per Mausklick durch die Lobbylandschaft navigieren kann. Das Projekt mitsamt den Daten ist *open-source* und auf Github verfügbar.

#### 2.2 Ziel

Die Daten liegen in einer MongoDB in einer losen Struktur vor. Möchte man nun maschinell darauf zugreifen, ist dies nicht ohne genauem Studiums dessen Inhalts möglich. Nun ist das Ziel dieser Arbeit, die relevantesten Daten in einem semantischen Graphen einfach verfügbar zu machen. Dabei konnte nicht der gesamte Inhalt beachtet werden. Als relevant haben sich die Positionen der Personen-Organisation-Verbindungen herausgestellt.

#### 2.3 Vorgehen

- 1. Die Daten des Lobbyradar müssen ausgewertet und priorisiert werden.
- 2. Aus den Daten muss eine Ontologie abgeleitet werden.
- 3. Sind die wichtigen Informationen identifiziert, werden sie in einen RDF-Graphen exportiert.
- 4. Ist der Graph aufgebaut, werden Standardsuchfunktionen per SPARQL definiert.
- 5. Auch ist eine Anbindung zum weiteren Informationsgewinn von Personen an DBpedia.

## 3 Analyse Lobbyradar

Lobbyradar enthält Knoten (Entities) und Kanten (Relations) welche in BSON persistiert sind. In RDF wären die Knoten die Klassen (Subjekt/Objekt) und die Relationen die Properties. Die Knoten enthalten sehr viele unterschiedliche Informationen welche sehr schwer in RDF dargestellt werden können:

```
{' id': '54bd3c768b934da06340f4c6',
 'aliases': [],
 'created': 'datetime.datetime(2015, 1, 19, 17, 18, 46, 529000)',
 'data': [{'auto': 'True',
   'created': 'datetime.datetime(2015, 1, 19, 17, 19, 9, 420000)',
   'desc': 'Quelle',
   'format': 'link'.
   'id': '3dc1416e38deac59076cd3f0d4e1235de79cb530207d06c28053134cc8aa7732',
   'key': 'source',
   'updated': 'datetime.datetime(2015, 1, 19, 17, 19, 9, 420000)',
   'value': {'remark': 'created by lobbyliste importer',
    'url': 'http://bundestag.de/blob/189476/8989cc5f5f65426215d7e0233704b20a/\
    lobbylisteaktuell-data.pdf'}},
  {'auto': 'True',
   'created': 'datetime.datetime(2015, 1, 19, 17, 19, 9, 420000)',
   'desc': 'Titel',
   'format': 'string',
   'id': '65873d29bd0ab6af91ef341689d28f4f0658cc851494a0ef34cfd07dd0cf5d42',
   'key': 'titles',
   'updated': 'datetime.datetime(2015, 1, 19, 17, 19, 9, 420000)',
   'value': 'Gesch\xe4ftsf\xfchrer'},
  {'auto': 'True',
   'created': 'datetime.datetime(2015, 1, 19, 17, 18, 46, 529000)',
   'desc': 'Titel',
   'format': 'string',
   'id': '1c98f43f0787b6dfcad25c38849ef3895bd26624a79c8fa9e6203c360d120fad',
   'key': 'titles',
   'updated': 'datetime.datetime(2015, 1, 19, 17, 18, 46, 529000)',
   'value': '2. Vorsitzender'}],
 'importer': 'lobbyliste',
 'name': 'Markus Hoymann',
 'search': ['markus hoymann'],
 'slug': 'markus hoymann',
 'tags': ['lobbyist', 'lobbyismus', 'executive'],
 'type': 'person',
 'updated': 'datetime.datetime(2015, 1, 19, 17, 19, 9, 426000)'}
```

Deshalb haben wir entschieden, von all diesen, nur die wichtigsten Eigenschaften abzubilden:

- id
- name
- created
- updated
- type (Person, Organisation)
- alias (nur bei Organisationen)
- tags (als Interessengebiete)

Die verschiedenen Relationen zwischen diesen Entitäten sind an der Struktur nicht erkennbar. Diese kann nur durch Analyse der Positionsinformationen ermittelt werden. *Position* ist dabei eine Metainformation des jeweiligen Eintrags.

Die verschiedenen Bezeichnungen für die Ämter und Anstellungsverhältnisse der Personen, also ihre Positionen in der Lobbyradar-Datenbank, sind jedoch stark arbiträr, gehorchen keiner Syntax und liegen nur als Literal vor. Es ist leider nicht ohne weiteres möglich einer Relation (Property) in RDF eine zusätzliche Bezeichnung als Literal zu geben. Dazu würden wir Hilfsknoten benötigen, welche den Graphen und somit die Suche stark verkomplizieren würden. Deswegen mussten wir diese Relationen in RDF-Properties umwandeln.

Da in der Datenbank auch viele Positionen mit semantisch gleichem Inhalt unterschiedliche Bezeichnungen haben, entweder weil keine einheitliche Benennung vorgegeben ist (z.B. Bundesminister der Finanzen, Finanzminister, Minister der Finanzen) oder weil die Importeure Tippfehler gemacht haben (executive, ececutive), haben wir uns entschieden, die wichtigsten Relationen semantisch zu gruppieren.

Die damit generierte RDF-Ontologie wurde so in der Datei "ontology.ttl" hierarchisch zusammengefasst.

Diese Zuordnung mussten wir händisch erledigen, aus Zeitgründen konnten wir also die restlichen Daten nicht Berücksichtigen.

## 4 Aufbau der Ontologie

#### 4.1 Konvertierung der Daten in RDF

Um die Daten in RDF überführen zu können, mussten wir zunächst eine hierarchische Ontologie in ontology.ttl nach Turtle-Syntax erstellen.

#### 4.2 T-Box

Grundsätzlich muss man sich bei der Erstellung der Ontologie entscheiden, ob man direkt bereits vorhandene Namespaces verwendet oder einen eigenen erstellt. Wir haben uns entschieden, eine Kombination aus vorhanenden Namespaces und einem eigenen zu erstellen, wobei die eigenen Klassen von den ähnlichsten, "offiziellen" Klassen abgeleitet wurden. Dabei haben wir die Erfahrung gemacht, dass es sehr schwer ist, für ein spezielles Themengebiet, taugliche (eindeutige) offizielle Klassen zu finden.

Die wichtigsten Klassen sind dabei:

```
# Partei
:Party a rdfs:Class;
  rdfs:subClassOf org:Organization .

# Regierung
:Government a rdfs:Class;
  rdfs:subClassOf org:Organization .

# Politiker
:Politician a rdfs:Class;
  rdfs:subClassOf foaf:Person .

# Lobbyist
:Lobbyist a rdfs:Class;
  rdfs:subClassOf foaf:Person .
```

Da aus dem Datensatz sehr schwer ersichtlich ist, ob eine Person ein Politiker oder Lobbyist ist, haben wir diese Kategorisierung noch nicht umgesetzt. Dafür würden wir vorschlagen, in Zukunft diese Entitäten mit Hilfe von OWL und einem guten Reasoner automatisch zu identifizieren. Aus Zeitgründen haben wir darauf verzichtet.

Auch mussten wir eigene Properties anlegen, zum Beispiel:

```
# Mitglied
:isMemberOf a rdf:Property ;
  rdfs:domain foaf:Person ;
```

```
rdfs:range :Organization .

#Vorsitzender
:isExecutiveOf rdfs:isSubPropertyOf :isMemberOf .

# steht in Verbindung mit einer Regierung
:isRelatedToGovernment rdfs:isSubPropertyOf :isMemberOf ;
  rdfs:domain foaf:Person ;
  rdfs:range :Government .
```

Mit diesen drei Properties oder deren subProperties werden die Relationen zwischen Personen und Organisationen oder Personen und Regierungen dargestellt. Diese subProperties sind beispielsweise:

```
# Stellvertretender Vorsitz, Vize-Präsident
:isVicePresidentOf rdfs:isSubPropertyOf :isExecutiveOf .

# Obmann
:isChairmanOf rdfs:isSubPropertyOf :isMemberOf .

#Staatssekretär
isSecretaryOfStateOf rdfs:isSubPropertyOf :isRelatedToGovernment .
```

Die Zuordnung war nicht trivial, da wir uns über passende Oberbegriffe Gedanken machen mussten und die Einordnung von Hand geschah.

#### 4.3 A-Box

Zunächst wurde über alle *Persons* und *Entities* in der Datenbank iteriert und dementsprechend Knoten im RDF-Graphen erstellt. Jeder dieser Knoten erhielt die Properties DC:identifier, DC:created und DC:modified. Wenn der Eintrag vom Typ Person war, wurde er der Klasse FOAF:Person zugeordnet, der Name wurde durch das RDF-Property FOAF:name angegeben. Da es sich um tatsächliche Personen handelt, fanden wir das Friend-Of-A-Friend-Vokabular angemessen.

Ansonsten erhielt er die Klasse ORG:Organization, deren Name als SKOS:prefLabel gespeichert wird. Wenn ein alias vorhanden war, wurde dieses in Form einer SKOS:altLabel-Property repräsentiert. Diese Wahl wurde für uns schon durch den ORG-Namespace getroffen, welche das Simple Knowledge Organization System (SKOS) referenziert und spezifiziert, dass SKOS:prefLabel für den rechtlich relevanten Namen einer Organisation und SKOS:altLabel für alle anderen bekannten Namen verwendet werden sollen.

Ausserdem wurden alle Tags (siehe BSON tags) als FOAF:topic\_interest-Property angefügt.

Für die Zuordnung der Relationen mussten wir zunächst Listen erstellen, die verschiedenen Bezeichnungen analog zu unserer Turtle-Ontologie zusammenfassen. Also zum Beispiel, dass die Bezeichnungen *Präsident, Vorsitz, Vorsitzender, Präsidentin* alle der Liste *Presidents* angehören und somit als RDF-Property OWN:isPresidentOf abgebildet werden.

Anschliessend iterierten wir zum Beispiel über alle Relationen vom Typ executive (oder ececutive, Vorsitzender). Dann prüften wir ob die angegebene Bezeichnung der Position in einer der Listen zu finden ist, die die RDF-subProperties von OWN:isExecutiveOf darstellen. Die Person-Organisation-Relation wurde dann mit der passendsten Property abgebildet, falls sie nicht in einer Liste enthalten war, wurde sie als OWN:isOtherExecutiveOf angefügt.

Analog verfahren wir mit allen Relationen vom Typ member, activity oder position und dem OWN:isMemberOf-Property oder den Relationen der Typen government und Bundesdatenschutzbeauftragte und OWN:isRelatedToGovernment.

Die A-Box und die T-Box stellen gemeinsam den semantischen Graphen dar.

## 5 Benutzung des Programms, Lobbyradar

Zu erst muss die Datei Graph.py und deren Funktionen importiert werden. Wichtig zu wissen ist, dass die Libraries pymongo, bson, rdflib, networkx und matplotlib vorhanden sein müssen.

#### 5.1 Nach Personen suchen

Mit der Methode search\_persons kann mittels Freitext nach Personen gesucht werden.

```
search_persons(name="angela m", limit=10)
[u'Angela Merkel', u'Angela Marquardt']
```

#### 5.2 Verbindungen einer Person ausgeben

Hat man den korrekten Namen der Person identifiziert, kann mit Hilfe der Methode **person\_connections** nach "connections", also in unserem Fall Organisationen, gesucht werden. Es wird eine Liste von Tripeln mit ('personenname', 'property', 'Organisationslabel') zurück gegeben. Dabei ist die Information, welcher tatsächliche RDF-Typ dahinter steckt, aus Übersichtsgründen weggelassen worden.

```
angela_connections = person_connections("Angela Merkel")
angela_connections[:2]

[(u'Angela Merkel',
    u'http://example.org/isOtherwiseRelatedToGovernment',
    u'Bundeskanzleramt'),
    (u'Angela Merkel',
    u'http://example.org/isOtherMemberOf',
    u'Atlantik-Br\xfccke e.V.')]
```

## 5.3 Resultat plotten

Die Methode **plot\_triples** visualisiert nun die Tripel in einem Graphen. Dabei werden die "Subjekte" Grün und die "Objekte" rot dargestellt. In unserem Fall sind die Personen grün und die Organisationen rot dargestellt.




Abbildung 1: Angela Merkels Verbindungen

Wie in Figure 1 zu sehen ist, werden die Relationen nicht betitelt, da die Übersichtlichkeit sonst enorm darunter gelitten hätte. Wir sind zum Entschluss gekommen, dass es wichtiger ist, das Vorhandensein einer Verbindung grafisch darzustellen. Um welche Art von Verbindung es sich dabei handelt, kann direkt vom Suchergebnis abgelesen werden.

#### 5.4 Nach Organisationen suchen

Mit der Methode **search\_organizations** kann mittels Freitext nach Organisationen gesucht werden.

```
search_organizations("SPD")
[u'SPD', u'SPD-NRW', u'SPD-Bundestagsfraktion', u'SPD Vorpommern']
```

## 5.5 Verbindungen einer Organisationen ausgeben

Nun kann mit der Methode **organization\_connections** nach Personen-Verbindungen dieser Organisation gesucht werden. Als Ergebnis erhält man wiederum Tripel, analog zur Methode **person\_connections**.

```
org_conn_tripple = organization_connections("SPD-Bundestagsfraktion")
org conn tripple[:4]
```

```
[(u'Bernhard Daldrup',
    u'http://example.org/isOtherMemberOf',
    u'SPD-Bundestagsfraktion'),
(u'Gabriele Hiller-Ohm',
    u'http://example.org/isOtherMemberOf',
    u'SPD-Bundestagsfraktion'),
(u'Daniela De Ridder',
    u'http://example.org/isOtherMemberOf',
    u'SPD-Bundestagsfraktion'),
(u'Nina Dr. Nina Scheer',
    u'http://example.org/isOtherMemberOf',
    u'SPD-Bundestagsfraktion')]
```

#### 5.6 Verbindungen einer Organisationen plotten

Diese können dann wiederum mit der Methode **plot\_triples** geplottet werden. Wenn der Graph zu groß wird, kann die Größe des Plots selbst über den Parameter **figsize?** angegeben werden. Siehe dazu Figure 2.

```
plot_tripples(org_conn_tripple, figsize=(25,25))
```

## 5.7 Nach Bundes-Organisationen suchen

Mit der Methode **search\_governmental** kann ausschliesslich nach Bundesorganisationen gesucht werden.

```
gov_organizations = search_governmental()
gov_organizations[:10]

[u'Nieders\xe4chsisches Kultusministerium',
    u'Bayrisches Staatsministerium f\xfcr Ern\xe4hrung, Landwirtschaft\
    und Forsten',
    u'Bayrisches Staatsministerium f\xfcr Arbeit und Soziales, Familie\
    und Integration',
    u'Ministerium f\xfcr Inneres und Kommunales Nordrhein-Westfalen',
    u'Hessisches Ministerium der Finanzen',
    u'Staatsministerium Baden-W\xfcrttemberg',
    u'Ministerium f\xfcr Landwirtschaft, Umwelt und Verbraucherschutz\
    Mecklenburg-Vorpommern',
    u'Staatskanzlei Sachsen-Anhalt',
    u'Nieders\xe4chsisches Ministerium f\xfcr Ern\xe4hrung,\
```




Abbildung 2: Mit SPD-Bundestagsfraktion im Zusammenhang stehende Personen

plot\_tripples(organization\_connections("Bundesministerium der Justiz"))




Abbildung 3: Mit Bundesministerium der Justiz im Zusammenhang stehende Personen

## 5.8 Eigene Sparql abfrage erstellen

Mit der Methode **search\_sparql** kann eine eigene Sparql Abfrage abgeschickt werden. Zurück erhält man ein rdflib-Abfrage-Resultat, dieses kann dann selbst nach belieben verwendet werden.

Als Beispiel kann die Ontologie analysiert werden:

```
http://example.org/isMemberOf -> http://example.org/isOtherMemberOf
http://example.org/isMemberOf -> http://example.org/isOrdinaryMemberOf
http://example.org/isExecutiveOf -> http://example.org/isChairmanOfManagementOf
http://example.org/isExecutiveOf -> http://example.org/isAdministrationBoardMemberOf
http://example.org/isExecutiveOf -> http://example.org/isManagementMemberOf
http://example.org/isExecutiveOf -> http://example.org/isDirectorOf
http://example.org/isMemberOf -> http://example.org/isRelatedToGovernment
http://example.org/isExecutiveOf -> http://example.org/isChairmanOfDirectorsBoardOf
...
```

#### 5.9 DBpedia-Informationen einer Person anzeigen

Mit der Methode **dbpedia\_person** können in DBpedia über eine spezifische Person informationen abgefragt werden. Momenan werden die DBpedia-URI und eine kleine Biographie der Person ausgegeben. Wenn es mehrere Personen gibt die gleich heißen werden mehrere Zeilen zurückgegeben.

```
dbpedia_person("Angela Merkel")
[(u'http://dbpedia.org/resource/Angela_Merkel',
    u'beschreibung sehr lange...')]
```

Uri von Angela Merkel bei dbpedia http://dbpedia.org/resource/Angela\_Merkel

Abstract von Angela Merkel aus dbpedia Angela Dorothea Merkel (\* 17. Juli 1954 in Hamburg als Angela Dorothea Kasner) ist eine deutsche Politikerin. Bei der Bundestagswahl am 2. Dezember 1990 errang Merkel, die in der DDR als Physikerin ausgebildet wurde und auch tätig war, erstmals ein Bundestagsmandat; in allen darauffolgenden sechs Bundestagswahlen wurde sie in ihrem Wahlkreis direkt gewählt. Von 1991 bis 1994 war Merkel Bundesministerin für Frauen und Jugend im Kabinett Kohl IV und von 1994 bis 1998 Bundesministerin für Umwelt, Naturschutz und Reaktorsicherheit im Kabinett Kohl V. Von 1998 bis 2000 amtierte sie als Generalsekretärin der CDU. Seit dem 10. April 2000 ist sie Bundesvorsitzende der CDU und seit dem 22. November 2005 2013 mittlerweile in der dritten Amtsperiode als Chefin von unterschiedlich zusammengesetzten Koalitionsregierungen deutsche Bundeskanzlerin. Sie ist die erste Frau und zugleich die achte Person in der Geschichte der Bundesrepublik, die dieses Amt innehat.

## 5.10 Eigene Sparql Anfrage an DBpedia senden

Möchte man nun noch genauere Informationen über die Person finden, kann man auch eine eigene Sparql Anfrage senden.

```
dbpedia_sparql_query("""
SELECT ?person ?birthDate
```

zurück erhält man ein JSON folgender Struktur, wobei die wichtigen Informationen unter json["results"]["bindings"] stehen. Auch ist wichtig zu wissen, dass die duplizierten Einträge aus den Einträgen aller Sprachen resultieren.

```
{
   "head":{
      "link":[
      ],
      "vars":[
         "person",
         "birthDate"
      ]
   },
   "results":{
      "distinct":false,
      "ordered":true,
      "bindings":[
         {
            "person":{
                "type":"uri",
                "value": "http://dbpedia.org/resource/Angela Merkel"
            },
            "birthDate":{
                "type": "typed-literal",
                "datatype": "http://www.w3.org/2001/XMLSchema#date",
                "value": "1954-07-17"
            }
         },
            "person":{
                "type": "uri",
                "value": "http://dbpedia.org/resource/Angela Merkel"
            },
            "birthDate":{
                "type": "typed-literal",
```

Dieses JSON könnte nun geparst und ausgelesen werden.

## 6 Nachbetrachtung

#### 6.1 RDF-Validierung

Uns ist aufgefallen, dass auf beliebige Property- und Klassennamen im RDF-Graphen referenziert werden kann, ohne dass die Existenz dieser gewährleistet ist. Uns ist bewusst, dass rdflib nicht die Informationen über alle Namespaces besitzten kann, man könnte jedoch einen Validator implementieren, welcher die angegebenen URIs prüft.

Wir sind zufällig auf das Problem gestoßen, dass durch Tippfehler auf Klassen oder Properties verwiesen wurde, welche nicht existierten und somit nicht im Suchresultat enthalten waren.

#### 6.2 Real-World-Datensatz

Das Projekt hat uns sehr gut gezeigt, dass Daten die von Menschen erhoben wurden, auch das menschliche Interpretationsvermögen zum verstehen der Daten nach sich ziehen. So mussten wir viel Zeit darin investieren, die vorhandene Struktur zu durchdringen.

## 7 Nachbetrachtung

#### 7.1 Weitere Klassifikationen

Anhand logischer Kombinationen der Verbindungen können die einzelnen Personen und Organisationen detaillierter klassifiziert werden. Zum Beispiel können Personen als Politiker und/oder Lobbyisten identifiziert werden. Dies ist anhand des Datensatzes nicht einfach möglich (es gibt kein *Flag* dazu).

Bei den Organisationen haben wir schon Regierungsorganisationen identifiziert, dies könnte analog für Parteien, wirtschaftliche Unternehmen, NGOs usw. fortgesetzt werden.

Um dies zu automatisieren, könnte man entweder OWL mit einen Reasoner und/oder eventuell sogar einen eigens trainierten Machine-Learning-Klassifikator einsetzen.

#### 7.2 SPARQL-Endpoint

Um die Daten im globalen Semantic Web zu Verfügung zu stellen könnte man analog zu DBpedia einen eigenen SPARQL-Endpoint anzubieten. Dies könnte alternativ über eine API geschehen.

#### 7.3 Fazit

Unsere Idee der semantischen Aufbereitung des Lobbyradars ist in Anbetracht der Beziehungen zwischen Personen und Organisationen geglückt. Dabei handelt es sich aber, wie man leicht sieht, zunächst um einen Anfang. Im Vergleich zum Lobbyradar, ist unsere Umsetzung ungleich weniger detailliert, dafür aber semantisch klarer. Die Ontologie legt die Struktur besser offen.